Ejercicio 05 · Motor recomendador reproducible

INF-8239 Ciencia de Datos II (UASD) · Unidad 04 · Consolidación de LAB08 y LAB09

Estudiante	Edwing Perez
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad04-05
Dataset	MovieLens Latest Small · GroupLens Research, University of Minnesota · uso académico con cita
Fecha de ejecución	2026-11-02

1. Datos, licencia, auditoría y corte temporal

MovieLens *Latest Small* (100.836 valoraciones, 610 usuarios, 9.742 películas, densidad 1,70 %, periodo 2017-01-01 a 2018-09-24) se descarga por script y **no se redistribuye**: el directorio `data/raw/` está excluido del repositorio. Licencia y condiciones: uso académico citando la fuente (Harper y Konstan, 2015, DOI 10.1145/2827872); el conjunto es de desarrollo y puede cambiar, por lo que se registra la fecha y el SHA-256 de la descarga. Auditoría: 0 nulos, 18 duplicados de texto, clases balanceadas. La partición es un **corte temporal leave-one-out** (la última valoración de cada usuario queda como prueba), con semilla 42; una separación aleatoria dejaría que el modelo aprendiera de interacciones posteriores.

2. Tabla principal de resultados

Configuración	Familia	HitRate@10	Cobertura	RMSE	Ajuste (s)	Modelo (KB)
mf40_alpha0.75	Híbrido	0.03918	0.1006	1.0211	7.92	3494
mf20_alpha0.75	Híbrido	0.03748	0.0775	1.0264	7.52	1883
mf20_alpha0.25	Híbrido	0.03237	0.1065	1.0264	7.52	1883
mf10_alpha0.75	Híbrido	0.03066	0.0577	1.0337	7.45	1077
mf10_alpha0.25	Híbrido	0.02896	0.0838	1.0337	7.45	1077
mf40_alpha0.25	Híbrido	0.02726	0.1227	1.0211	7.92	3494
popularidad	Referencia	0.02131	0.0010	—	0.00	0
contenido	Referencia	0.00000	0.1907	—	0.00	0

Híbrido principal (α=0,75, 20 factores): RMSE 1.0264 · HitRate@10 0.03748 · cobertura 0.0775 · tiempo 7.58 s · modelo 1883 KB. Referencias: la **popularidad** acierta en el 2,13 % de los casos retenidos con 0,10 % de cobertura (10 películas para todos), y el **contenido** tiene la mayor cobertura (19,07 %) pero **HitRate@10 = 0**: recomienda lo más parecido, nunca lo retenido.

3. Figuras

Figura 1. Top-10 de popularidad (baseline).

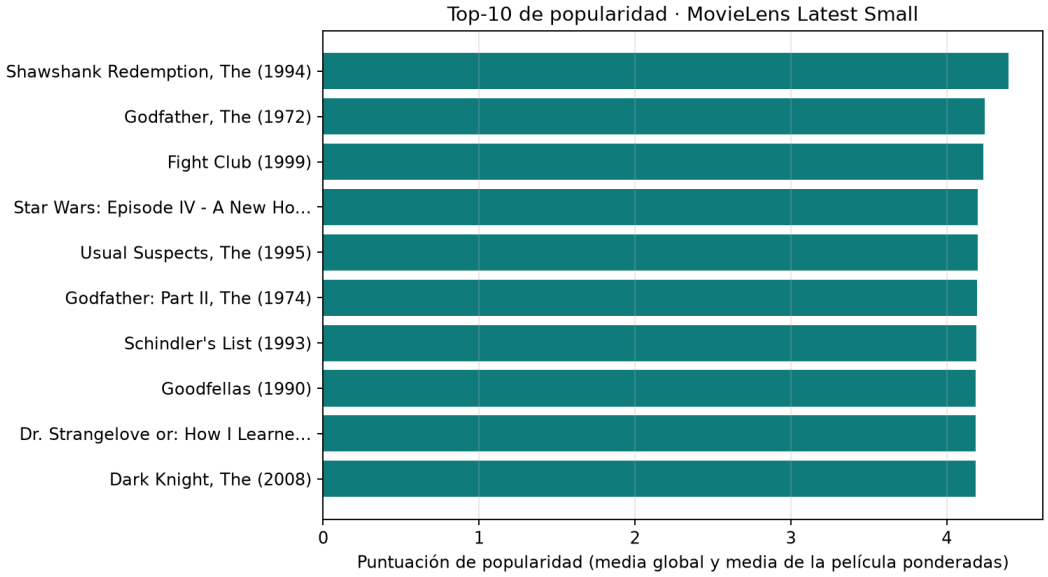
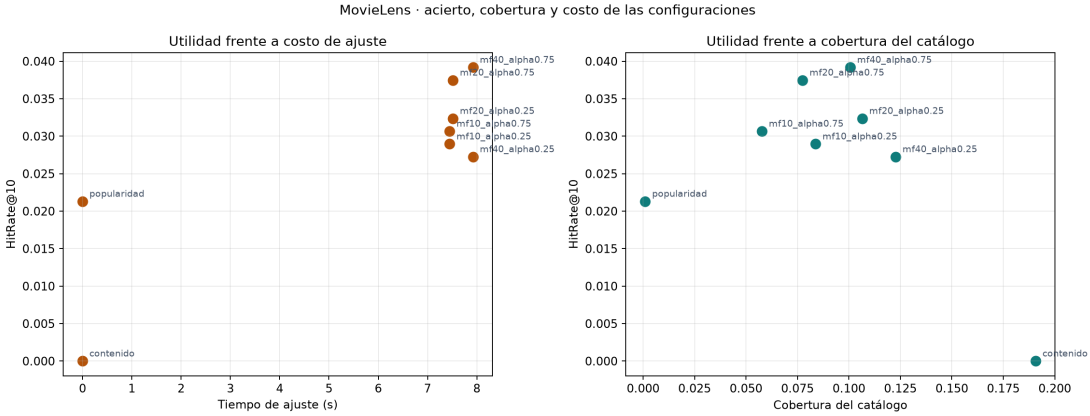


Figura 2. Utilidad frente a costo de ajuste y frente a cobertura del catálogo.



4. Conclusión y decisión

Con la configuración principal (`alpha=0.75`, 20 factores, 12 épocas, semilla 42) el **HitRate@10 es 0,03748**: menos de 4 de cada 100 usuarios con valoración retenida encontraron esa película en las primeras 10 posiciones. Al bajar a `alpha=0.25` el acierto cae a 0,03237 y la cobertura sube de 7,75 % a 10,65 %. Con tres semillas y tres tamaños de modelo (18 configuraciones en `reports/pareto_results.csv`) el HitRate@10 va de 0,02044 a 0,05111: **la varianza entre semillas es mayor que la diferencia entre valores de `alpha`**, por lo que una sola ejecución no sostiene conclusiones sobre `alpha`.

Cobertura del catálogo

La cobertura baja con `alpha` alto (7,75 % con 0,75 frente a 10,65 % con 0,25) y sube con más factores (12,4 %–12,6 % con 40 factores). En el mejor caso medido, solo 1 de cada 10 películas del catálogo aparece alguna vez en las listas: el sistema concentra las recomendaciones. Es el indicador de burbuja de filtro que exige el manual, y obliga a reportar cobertura junto al HitRate y nunca por separado.

Comportamiento del usuario frío

`reports/profile_recommendations.csv` documenta los tres perfiles:

Perfil	Usuario	Valoraciones en entrenamiento	Comportamiento observado
Historial amplio	414	2.697	Lista del híbrido con señal colaborativa dominante (dramas y clásicos con muchas valoraciones)
Historial pequeño	53	19	Señal de contenido con más peso; lista más estable y genérica (*The Godfather*, *Annie Hall*, *Apocalypse Now*)
Usuario nuevo	999999	0	**Fallback de popularidad**: *Forrest Gump*, *The Shawshank Redemption*, *Pulp Fiction*…; la lista existe pero **no es personalizada**

Configuración seleccionada y evidencia

Se elige **`alpha=0.75` con 20 factores, 12 épocas y semilla 42**, por evidencia y no por preferencia: (1) es la configuración del manual; (2) con las tres semillas, `alpha=0.75` domina en HitRate@10 en 6 de 9 comparaciones por semilla; (3) el RMSE no depende de `alpha`; (4) su costo es intermedio. La **frontera de Pareto** (utilidad HitRate@10 frente a costo) la ocupan tres configuraciones:

Semilla	Factores	α	HitRate@10	Cobertura	Tiempo (mediana)	Modelo
7	10	0,75	0,04089	5,46 %	7,48 s	1,077 MB
2024	10	0,75	0,05111	5,79 %	7,56 s	1,077 MB
2024	20	0,75	0,03578	7,49 %	7,42 s	1,883 MB

Ninguna otra configuración las domina. La lectura honesta es que **el tamaño del modelo y la utilidad son los ejes que discriminan**, no el tiempo: las tres configuraciones frontera tienen el mayor HitRate@10 y el menor tamaño (10 factores) o un tamaño intermedio con más cobertura. Con `alpha=0.25` ninguna configuración llega a la frontera: baja el acierto en el Top-10 y sube la cobertura, es decir, cambia *qué* se recomienda, no *cuántas* películas distintas aparecen.

Costo computacional

Configuración	Tiempo de ajuste (mediana de 3)	Rango observado	Tamaño del modelo	RMSE
10 factores	7,48–7,56 s	7,397–7,567 s	1,077 MB	1,0265–1,0337
20 factores	7,42–7,60 s	7,393–7,741 s	1,883 MB	1,0259–1,0266
40 factores	7,51–7,55 s	7,454–7,729 s	3,494 MB	1,0168–1,0244

El tiempo de ajuste es **prácticamente constante** (±0,1 s) porque lo domina el número de observaciones × épocas del SGD, no el número de factores; el costo que sí crece de forma clara es el **tamaño del modelo** (1,08 $\rightarrow$ 1,88 $\rightarrow$ 3,49 MB, ×3,2). Al repetir la medición, la frontera de Pareto cambió entre ejecuciones (con una sola corrida por configuración entraba una de 40 factores): la diferencia entre configuraciones es menor que el ruido de medición, por lo que **no se puede afirmar que una configuración sea más rápida que otra**. Medición en CPU de escritorio, sin GPU.

Riesgo principal y mitigación

Riesgo principal: burbuja de filtro por concentración, agravada por el desbalance de las señales (la cobertura no supera el 13 % en ninguna configuración). **Mitigación aplicada:** documentar la cobertura y el HitRate juntos, declarar el fallback de popularidad como no personalizado, comparar explícitamente `alpha` alto y bajo, y reportar la frontera de Pareto en lugar de elegir el modelo más grande. Riesgos secundarios: sesgo de selección (solo consumos ya realizados), ausencia de demografía (no se afirman resultados por grupo) y retroalimentación (todo se evalúa offline con corte temporal, sin usar interacciones futuras).

Uso responsable de IA. El asistente de IA apoyó la redacción de las tarjetas, la extracción de la lógica del híbrido a `src/inf8239_u03/hybrid.py` (verificada con métricas idénticas a las del script base) y la corrección de un error de compatibilidad con NumPy 2. El estudiante conserva la responsabilidad sobre los datos, el código, las referencias y estas conclusiones; los detalles están en `AI_USE_DECLARATION.md`. Los errores del catálogo no son preferencias: las señales miden coincidencias de categorías y patrones de interacción, nunca garantizan que algo le gustará a una persona.