Ejercicio 05 · Motor recomendador reproducible

INF-8239 Ciencia de Datos II (UASD) · Unidad 03 · Consolidación de LAB08 y LAB09

Estudiante	Edwing Perez
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad04-05
Dataset	MovieLens Latest Small · GroupLens Research, University of Minnesota · uso académico con cita
Fecha de ejecución	2026-11-05

1. Datos, licencia, auditoría y corte temporal

MovieLens *Latest Small* (100.836 valoraciones, 610 usuarios, 9.742 películas, densidad 1,70 %, periodo 1996-03-29 a 2018-09-24) se descarga por script y **no se redistribuye**: el directorio `data/raw/` está excluido del repositorio. Licencia y condiciones: uso académico citando la fuente (Harper y Konstan, 2015, DOI 10.1145/2827872); el conjunto es de desarrollo y puede cambiar, por lo que se registra la fecha y el SHA-256 de la descarga. Auditoría (`reports/audit_summary.json`): 0 nulos en ratings.csv y movies.csv, 5 títulos duplicados en el catálogo (5 títulos distintos), 0 pares usuario–película repetidos y 18 ítems del catálogo sin ninguna valoración (9.742 − 9.724). La distribución de valoraciones es **unimodal** (moda 4,0 con 26.818 valoraciones, 26,6 %), no balanceada. La partición es un **corte temporal leave-one-out** (la última valoración de cada usuario queda como prueba), con semilla 42; una separación aleatoria dejaría que el modelo aprendiera de interacciones posteriores.

2. Tabla principal de resultados

Tabla consolidada de una semilla (6 configuraciones híbridas + 2 referencias): `reports/pareto_results.csv`.

Configuración	Familia	HitRate@10	Cobertura	RMSE	Ajuste (s)	Modelo (KB
mf40_alpha0.75	Híbrido	0.03918	0.1006	1.0211	7.96	3494
mf20_alpha0.75	Híbrido	0.03748	0.0775	1.0264	7.84	1883
mf20_alpha0.25	Híbrido	0.03237	0.1065	1.0264	7.84	1883
mf10_alpha0.75	Híbrido	0.03066	0.0577	1.0337	7.77	1077
mf10_alpha0.25	Híbrido	0.02896	0.0838	1.0337	7.77	1077
mf40_alpha0.25	Híbrido	0.02726	0.1227	1.0211	7.96	3494
popularidad	Referencia	0.02131	0.0010	—	0.00	0
contenido	Referencia	0.00000	0.1907	—	0.00	0

Nota: los tiempos de ajuste de esta tabla son los de su propio archivo (`reports/pareto_results.csv`). Los archivos de la entrega se generaron en **corridas distintas** (mismo código y misma semilla), de modo que una misma configuración aparece con tiempos de ajuste ligeramente distintos según el archivo: no es una contradicción, **la única fuente de verdad de cada cifra es su archivo**. Para citar el tiempo de una configuración se usa el del JSON del híbrido: 7,75 s para α=0,75 (`reports/hybrid_metrics_alpha075.json`) y 7,57 s para α=0,25 (`reports/hybrid_metrics_alpha025.json`).

Híbrido principal (α=0,75, 20 factores, `reports/hybrid_metrics_alpha075.json`): RMSE 1,0264 · HitRate@10 0,03748 · cobertura 7,75 % · tiempo 7,75 s · modelo 1.883 KB. Con α=0,25 (`reports/hybrid_metrics_alpha025.json`): RMSE 1,0264 · HitRate@10 0,03237 · cobertura 10,65 % · tiempo 7,57 s. Referencias: la **popularidad** acierta en el 2,13 % de los casos retenidos con 0,10 % de cobertura (10 películas para todos), y el **contenido** tiene la mayor cobertura (19,07 %) pero **HitRate@10 = 0**: recomienda lo más parecido, nunca lo retenido.

3. Frontera de Pareto multistamillas

Tres semillas × tres tamaños de modelo × dos valores de α = 18 configuraciones sobre el mismo corte temporal, con el tiempo de ajuste medido tres veces por configuración y reportado como mediana. Tabla completa: `reports/pareto_multiseed.csv`; figura: `reports/pareto.png`.

Semilla	Factores	α	HitRate@10	Cobertura	Ajuste (s)	Modelo (KB)
42	10	0,75	0.03066	0.0577	7.42	1077
2024	10	0,75	0.05111	0.0579	7.50	1077

Nota: los tiempos de esta tabla son los de su propio archivo (`reports/pareto_multiseed.csv`: mediana de tres repeticiones, corrida propia), no los de la tabla consolidada de la sección 2; la nota de esa sección explica por qué conviven tiempos distintos de la misma configuración.

Con las 18 configuraciones el HitRate@10 va de 0,02044 a 0,05111: la varianza entre semillas es mayor que la diferencia entre valores de α, de modo que una sola ejecución no sostiene conclusiones sobre α.

4. Figuras

Figura 1. Top-10 de popularidad (baseline).

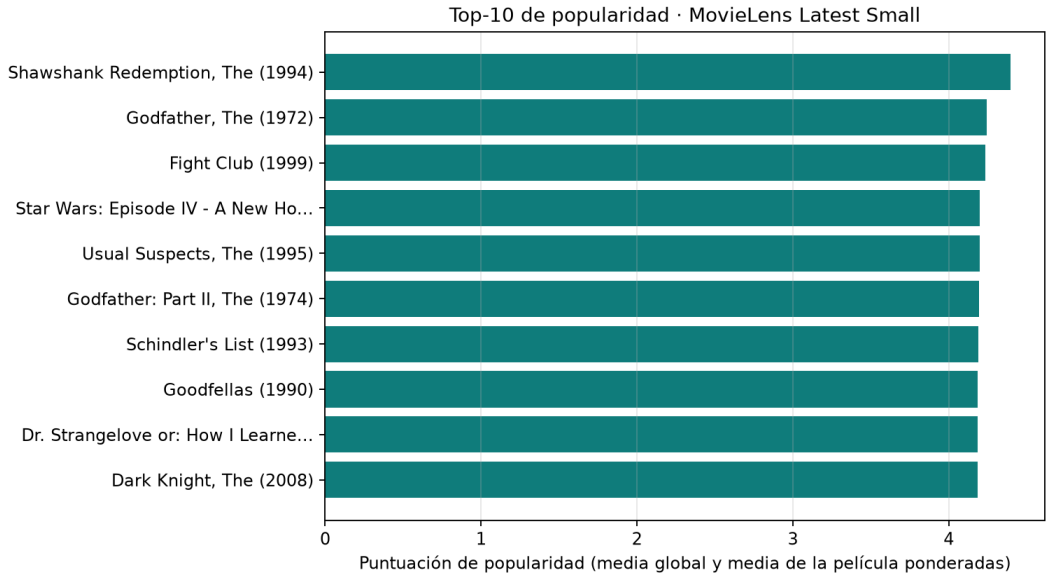
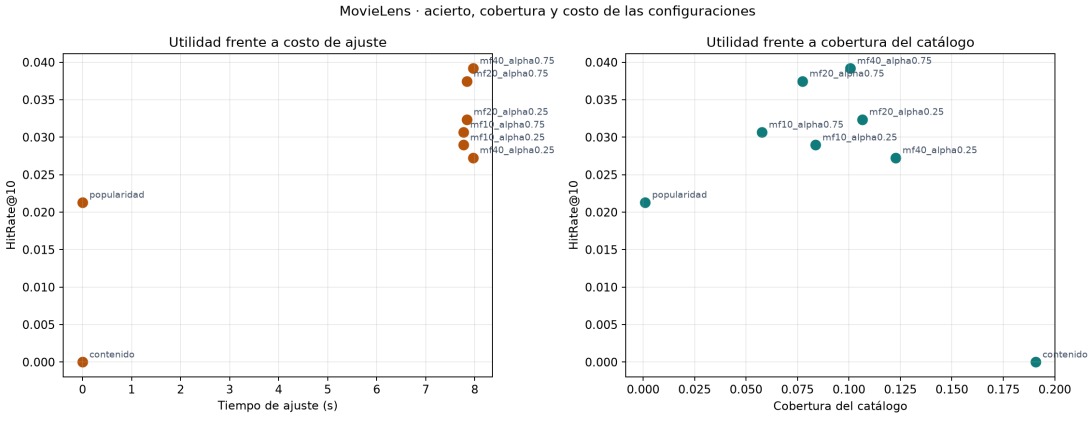


Figura 2. Utilidad frente a costo de ajuste y frente a cobertura del catálogo (configuraciones de una semilla).



5. Conclusión y decisión

Con la configuración principal (`alpha=0.75`, 20 factores, 12 épocas, semilla 42) el **HitRate@10 es 0,03748**: menos de 4 de cada 100 usuarios con valoración retenida encontraron esa película en las primeras 10 posiciones. Al bajar a `alpha=0.25` el acierto cae a 0,03237 y la cobertura sube de 7,75 % a 10,65 %. Con tres semillas y tres tamaños de modelo (18 configuraciones en `reports/pareto_multiseed.csv`) el HitRate@10 va de 0,02044 a 0,05111: **la varianza entre semillas es mayor que la diferencia entre valores de `alpha`**, por lo que una sola ejecución no sostiene conclusiones sobre `alpha`.

Las dos tablas de Pareto del repositorio no se confunden: `reports/pareto_multiseed.csv` contiene las 18 configuraciones multistamillas (con la columna `is_pareto`) y `reports/pareto_results.csv` la tabla consolidada de una sola semilla (8 filas: 6 configuraciones híbridas y las 2 referencias), que escribe el notebook.

Cobertura del catálogo

La cobertura baja con `alpha` alto (7,75 % con 0,75 frente a 10,65 % con 0,25) y sube con más factores (9,49 %–12,64 % con 40 factores). En el mejor caso medido aparece 12,64 % del catálogo (algo más de 1 de cada 8 películas) en las listas: el sistema concentra las recomendaciones. Es el indicador de burbuja de filtro que exige el manual, y obliga a reportar cobertura junto al HitRate y nunca por separado.

Comportamiento del usuario frío

`reports/profile_recommendations.csv` documenta los tres perfiles:

Perfil	Usuario	Valoraciones en entrenamiento	Comportamiento observado
Historial amplio	414	2.697	Lista del híbrido con señal colaborativa dominante (dramas y clásicos con muchas valoraciones)
Historial pequeño	53	19	Señal de contenido con más peso; lista más estable y genérica (*The Godfather*, *Annie Hall*, *Apocalypse Now*)
Usuario nuevo	999999	0	**Fallback de popularidad**: *Forrest Gump (1994)*, *Shawshank Redemption, The (1994)*, *Pulp Fiction (1994)*…; la lista existe pero **no es personalizada**

Configuración seleccionada y evidencia

Se elige **`alpha=0.75` con 20 factores, 12 épocas y semilla 42**, por evidencia y no por preferencia: (1) es la configuración del manual; (2) con las tres semillas, `alpha=0.75` domina en HitRate@10 en 8 de 9 comparaciones por semilla; (3) el RMSE no depende de `alpha`; (4) su costo es intermedio. La **frontera de Pareto** (utilidad HitRate@10 frente a costo) la ocupan dos configuraciones de `reports/pareto_multiseed.csv`:

Semilla	Factores	α	HitRate@10	Cobertura	Tiempo (mediana)	Modelo
42	10	0,75	0,03066	5,77 %	7,42 s	1.077 KB
2024	10	0,75	0,05111	5,79 %	7,50 s	1.077 KB

Ninguna otra configuración las domina. La lectura honesta es que **el tiempo de ajuste y la utilidad son los ejes que discriminan** y el tamaño del modelo los acompaña: en esta corrida la frontera se queda en 10 factores (el modelo más pequeño) porque esa configuración tarda menos y acierta igual o más que las de 20 y 40 factores. Con `alpha=0.25` ninguna configuración llega a la frontera: baja el acierto en el Top-10 y sube la cobertura, es decir, cambia *qué* se recomienda, no *cuántas* películas distintas aparecen.

Costo computacional

Configuración	Tiempo de ajuste (mediana de 3)	Tamaño del modelo	RMSE
10 factores	7,42–7,54 s	1.077 KB	1,0265–1,0337
20 factores	7,61–7,74 s	1.883 KB	1,0259–1,0266
40 factores	7,51–7,74 s	3.494 KB	1,0168–1,0244

El tiempo de ajuste es **prácticamente constante** (±0,3 s) porque lo domina el número de observaciones × épocas del SGD, no el número de factores; el costo que sí crece de forma clara es el **tamaño del modelo** (1.077 → 1.883 → 3.494 KB, ×3,2). Al repetir la medición, la frontera de Pareto cambió entre ejecuciones (en corridas anteriores entraba también una de 20 o de 40 factores): la diferencia entre configuraciones es menor que el ruido de medición, por lo que **no se puede afirmar que una configuración sea más rápida que otra**. Medición en CPU de escritorio, sin GPU.

Riesgo principal y mitigación

Riesgo principal: burbuja de filtro por concentración, agravada por el desbalance de las señales (la cobertura no supera el 12,6 % en ninguna configuración). **Mitigación aplicada:** documentar la cobertura y el HitRate juntos, declarar el fallback de popularidad como no personalizado, comparar explícitamente `alpha` alto y bajo, y reportar la frontera de Pareto en lugar de elegir el modelo más grande. Riesgos secundarios: sesgo de selección (solo consumos ya realizados), ausencia de demografía (no se afirman resultados por grupo) y retroalimentación (todo se evalúa offline con corte temporal, sin usar interacciones futuras).

Uso responsable de IA. El asistente de IA apoyó la redacción de las tarjetas, la extracción de la lógica del híbrido a `src/inf8239_u03/hybrid.py` (verificada con métricas idénticas a las del script base), la corrección de un error de compatibilidad con NumPy 2 y la auditoría de consistencia entre los artefactos de `reports/` y la documentación. El estudiante conserva la responsabilidad sobre los datos, el código, las referencias y estas conclusiones; los detalles están en `AI_USE_DECLARATION.md`. Los errores del catálogo no son preferencias: las señales miden coincidencias de categorías y patrones de interacción, nunca garantizan que algo le gustará a una persona.