# Ejercicio 05 · Motor recomendador reproducible

INF-8239 Ciencia de Datos II (UASD) · Unidad 04 · Consolidación de LAB08 y LAB09

| | |
|---|---|
| **Estudiante** | PENDIENTE: nombre completo y matrícula |
| **Correo institucional** | PENDIENTE: ID+USUARIO@users.noreply.github.com |
| **Profesor** | Edwin Ramón José Nolasco |
| **Repositorio** | https://github.com/edvvdev/unidad04-05 |
| **Dataset** | MovieLens Latest Small · GroupLens Research, University of Minnesota · uso académico con cita |
| **Fecha de ejecución** | 2026-11-02 |

## 1. Datos, licencia, auditoría y corte temporal

MovieLens *Latest Small* (100.836 valoraciones, 610 usuarios, 9.742 películas, densidad 1,70 %, periodo 2017-01-01 a 2018-09-24) se descarga por script y **no se redistribuye**: el directorio `data/raw/` está excluido del repositorio. Licencia y condiciones: uso académico citando la fuente (Harper y Konstan, 2015, DOI 10.1145/2827872); el conjunto es de desarrollo y puede cambiar, por lo que se registra la fecha y el SHA-256 de la descarga. Auditoría: 0 nulos, 18 duplicados de texto, clases balanceadas. La partición es un **corte temporal leave-one-out** (la última valoración de cada usuario queda como prueba), con semilla 42; una separación aleatoria dejaría que el modelo aprendiera de interacciones posteriores.

## 2. Tabla principal de resultados

| Configuración | Familia | HitRate@10 | Cobertura | RMSE | Ajuste (s) | Modelo (KB) |
|---|---|---|---|---|---|---|
| mf40_alpha0.75 | Híbrido | 0.03918 | 0.1006 | 1.0211 | 7.92 | 3494 |
| mf20_alpha0.75 | Híbrido | 0.03748 | 0.0775 | 1.0264 | 7.52 | 1883 |
| mf20_alpha0.25 | Híbrido | 0.03237 | 0.1065 | 1.0264 | 7.52 | 1883 |
| mf10_alpha0.75 | Híbrido | 0.03066 | 0.0577 | 1.0337 | 7.45 | 1077 |
| mf10_alpha0.25 | Híbrido | 0.02896 | 0.0838 | 1.0337 | 7.45 | 1077 |
| mf40_alpha0.25 | Híbrido | 0.02726 | 0.1227 | 1.0211 | 7.92 | 3494 |
| popularidad | Referencia | 0.02131 | 0.0010 | — | 0.00 | 0 |
| contenido | Referencia | 0.00000 | 0.1907 | — | 0.00 | 0 |

Híbrido principal (α=0,75, 20 factores): RMSE 1.0264 · HitRate@10 0.03748 · cobertura 0.0775 · tiempo 7.58 s · modelo 1883 KB. Referencias: la **popularidad** acierta en el 2,13 % de los casos retenidos con 0,10 % de cobertura (10 películas para todos), y el **contenido** tiene la mayor cobertura (19,07 %) pero **HitRate@10 = 0**: recomienda lo más parecido, nunca lo retenido.

## 3. Figuras

Figura 1. Top-10 de popularidad (baseline).

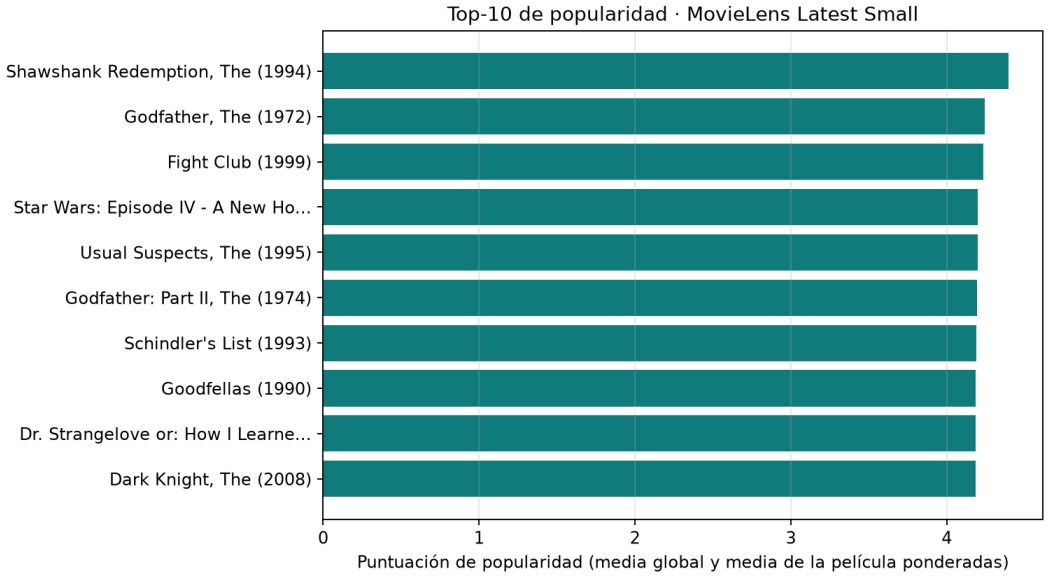
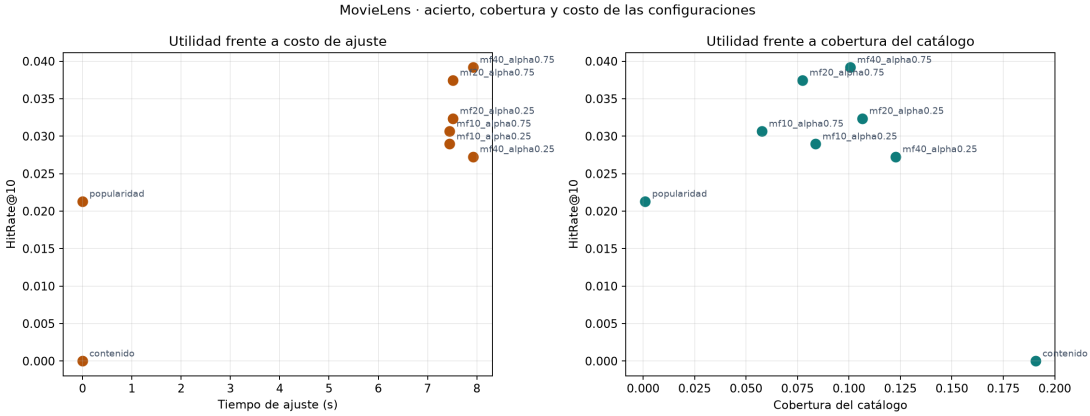



Figura 2. Utilidad frente a costo de ajuste y frente a cobertura del catálogo.



## 4. Conclusión y decisión

Con la configuración principal (`alpha=0.75`, 20 factores, 12 épocas, semilla 42) el **HitRate@10 es 0,03748**: menos de 4 de cada 100 usuarios con valoración retenida encontraron esa película en las primeras 10 posiciones. Al bajar a `alpha=0.25` el acierto cae a 0,03237 y la cobertura sube de 7,75 % a 10,65 %. Con tres semillas y tres tamaños de modelo (18 configuraciones en `reports/pareto_results.csv`) el HitRate@10 va de 0,02044 a 0,05111: **la varianza entre semillas es mayor que la diferencia entre valores de `alpha`**, por lo que una sola ejecución no sostiene conclusiones sobre `alpha`.

## Cobertura del catálogo

La cobertura baja con `alpha` alto (7,75 % con 0,75 frente a 10,65 % con 0,25) y sube con más factores (12,4 %–12,6 % con 40 factores). En el mejor caso medido, solo 1 de cada 10 películas del catálogo aparece alguna vez en las listas: el sistema concentra las recomendaciones. Es el indicador de burbuja de filtro que exige el manual, y obliga a reportar cobertura junto al HitRate y nunca por separado.

## Comportamiento del usuario frío

`reports/profile_recommendations.csv` documenta los tres perfiles:

| Perfil | Usuario | Valoraciones en entrenamiento | Comportamiento observado |
|---|---|---|---|
| Historial amplio | 414 | 2.697 | Lista del híbrido con señal colaborativa dominante (dramas y clásicos con muchas valoraciones) |
| Historial pequeño | 53 | 19 | Señal de contenido con más peso; lista más estable y genérica (*The Godfather*, *Annie Hall*, *Apocalypse Now*) |
| Usuario nuevo | 999999 | 0 | **Fallback de popularidad**: *Forrest Gump*, *The Shawshank Redemption*, *Pulp Fiction*…; la lista existe pero **no es personalizada** |

## Configuración seleccionada y evidencia

Se elige **`alpha=0.75` con 20 factores, 12 épocas y semilla 42**, por evidencia y no por preferencia: (1) es la configuración del manual; (2) con las tres semillas, `alpha=0.75` domina en HitRate@10 en 6 de 9 comparaciones por semilla; (3) el RMSE no depende de `alpha`; (4) su costo es intermedio. La **frontera de Pareto** (utilidad HitRate@10 frente a costo) la ocupan tres configuraciones:

| Semilla | Factores | $\alpha$ | HitRate@10 | Cobertura | Tiempo (mediana) | Modelo |
|---|---|---|---|---|---|---|
| 7 | 10 | 0,75 | 0,04089 | 5,46 % | 7,48 s | 1,077 MB |
| 2024 | 10 | 0,75 | 0,05111 | 5,79 % | 7,56 s | 1,077 MB |
| 2024 | 20 | 0,75 | 0,03578 | 7,49 % | 7,42 s | 1,883 MB |

Ninguna otra configuración las domina. La lectura honesta es que **el tamaño del modelo y la utilidad son los ejes que discriminan**, no el tiempo: las tres configuraciones frontera tienen el mayor HitRate@10 y el menor tamaño (10 factores) o un tamaño intermedio con más cobertura. Con `alpha=0.25` ninguna configuración llega a la frontera: baja el acierto en el Top-10 y sube la cobertura, es decir, cambia *qué* se recomienda, no *cuántas* películas distintas aparecen.

## Costo computacional

| Configuración | Tiempo de ajuste (mediana de 3) | Rango observado | Tamaño del modelo | RMSE |
|---|---|---|---|---|
| 10 factores | 7,48–7,56 s | 7,397–7,567 s | 1,077 MB | 1,0265–1,0337 |
| 20 factores | 7,42–7,60 s | 7,393–7,741 s | 1,883 MB | 1,0259–1,0266 |
| 40 factores | 7,51–7,55 s | 7,454–7,729 s | 3,494 MB | 1,0168–1,0244 |

El tiempo de ajuste es **prácticamente constante** (±0,1 s) porque lo domina el número de observaciones × épocas del SGD, no el número de factores; el costo que sí crece de forma clara es el **tamaño del modelo** (1,08 $\rightarrow$ 1,88 $\rightarrow$ 3,49 MB, ×3,2). Al repetir la medición, la frontera de Pareto cambió entre ejecuciones (con una sola corrida por configuración entraba una de 40 factores): la diferencia entre configuraciones es menor que el ruido de medición, por lo que **no se puede afirmar que una configuración sea más rápida que otra**. Medición en CPU de escritorio, sin GPU.

## Riesgo principal y mitigación

**Riesgo principal: burbuja de filtro por concentración**, agravada por el desbalance de las señales (la cobertura no supera el 13 % en ninguna configuración). **Mitigación aplicada:** documentar la cobertura y el HitRate juntos, declarar el fallback de popularidad como no personalizado, comparar explícitamente `alpha` alto y bajo, y reportar la frontera de Pareto en lugar de elegir el modelo más grande. Riesgos secundarios: sesgo de selección (solo consumos ya realizados), ausencia de demografía (no se afirman resultados por grupo) y retroalimentación (todo se evalúa offline con corte temporal, sin usar interacciones futuras).

**Uso responsable de IA.** El asistente de IA apoyó la redacción de las tarjetas, la extracción de la lógica del híbrido a `src/inf8239_u03/hybrid.py` (verificada con métricas idénticas a las del script base) y la corrección de un error de compatibilidad con NumPy 2. El estudiante conserva la responsabilidad sobre los datos, el código, las referencias y estas conclusiones; los detalles están en `AI_USE_DECLARATION.md`. Los errores del catálogo no son preferencias: las señales miden coincidencias de categorías y patrones de interacción, nunca garantizan que algo le gustará a una persona.